

# PWS Cup 2026 競技ルールブック (orientation-20260730c)

## 目次

|                                                              |    |
|--------------------------------------------------------------|----|
| 記法・用語                                                        | 2  |
| 1. 大会概要・目的                                                   | 3  |
| 1.1 この競技の物語                                                  | 3  |
| 2. スケジュール・エントリー                                              | 4  |
| 3. データ仕様                                                     | 5  |
| 3.1 コホートの構造（非共有ブロック $P_i$ と共有ブロック $S_{ij}$ ）                 | 5  |
| 3.2 配布の公平性の担保                                                | 7  |
| 4. 競技フロー                                                     | 8  |
| 4.1 攻撃①メンバーシップ推論（MIA）                                        | 8  |
| 4.2 攻撃②属性推論（AIA）                                             | 8  |
| 5. 提出物・フォーマットと自己採点                                           | 9  |
| 5.1 加工提出 C                                                   | 9  |
| 5.2 攻撃提出 F                                                   | 10 |
| 5.3 提出できる回数                                                  | 10 |
| 5.4 ローカル環境での自己採点                                             | 10 |
| 5.5 提出時フォーマットチェック                                            | 11 |
| 5.6 リーダーボードの見方                                               | 11 |
| 6. 採点方式                                                      | 11 |
| 6.0 採点の全体像                                                   | 11 |
| 6.1 有用性 U（4つの観点の最小）                                          | 12 |
| 6.1.1 $U_{\text{gen}}$ 一般有用性 = min(周辺分布, pMSE, 発症曲線)         | 12 |
| 6.1.2 $U_{\text{spec}}$ 特定タスクでの結果忠実度 = min(結論一致, 判別再現)       | 13 |
| 6.1.3 $U_{\text{rare}}$ 希少群の有用性 = min(希少率, プロファイル, 発症, 同時分布) | 14 |
| 6.1.4 $U_{\text{valid}}$ 妥当性 = mean(打ち切り整合, 関係の非捏造)          | 14 |
| 6.2 匿名性 Anon（2つの攻撃のうち悪いほう）                                   | 15 |
| 6.2.1 MIA 成分（メンバーシップ推論）                                      | 15 |
| 6.2.2 AIA 成分（属性推論）                                           | 17 |
| 6.3 攻撃力（ベストアタック賞）                                            | 18 |
| 6.4 予備戦と本戦の合計                                                | 18 |

|                     |    |
|---------------------|----|
| 7. 運用規則・参加規約        | 18 |
| 7.1 実行基盤            | 18 |
| 7.2 提出物の公開          | 19 |
| 7.3 運営体制            | 19 |
| 7.4 監査条項            | 19 |
| 7.5 LLM 等の生成 AI の利用 | 20 |
| 7.6 賞               | 20 |
| 8. スターターキット（配布物一式）  | 20 |

本書について: 本書は PWS Cup 2026 の競技ルールの正本です。採点方式・提出フォーマット・参加規約は本書の記載を基準とします。競技の進行にともなって更新することがあります。更新した場合は版を改め、コンテストの Web サイトでお知らせします。

## 記法・用語

本書を通じて次の記号を使います。添字  $i$  はチーム  $i$  を表します。

| 記号                         | 意味                                                                                             | 誰が持つか        | 参加者への配布                            |
|----------------------------|------------------------------------------------------------------------------------------------|--------------|------------------------------------|
| <b>A（母集団）</b>              | 全国を代表する、ひとつの母集団。競技データはすべてこの A から切り出す。                                                          | 事務局のみ        | なし                                 |
| <b>A_bg（背景データ）</b>         | 母集団 A のうち、どのチームのコホートにも含まれない部分。攻撃の基準（本物らしさの物差し）や、チーム間の配布の公平性をそろえる基準に使う。希少な患者の割合はコホートと同じにそろえてある。 | 全チーム共通       | あり（全チームに同じもの）                      |
| <b>B（元データ）</b>             | A から切り出して各チームに配られる健診コホート（本物相当の疑似データ）。参加者はこれを匿名化する。チーム $i$ のものを $B_i$ と書く。                      | 各チームが自分のぶんだけ | あり（自分の $B_i$ のみ。他チームの $B$ は見られません） |
| <b>B_self（自己採点用の拡張版 B）</b> | 加工フェーズで自チームに配る、真値列を含んだ B。手元で全観点を自己採点するために使う (§5.4)。                                            | 各チームが自分のぶんだけ | あり（自分のぶんのみ）                        |

| 記号                   | 意味                                                                                                                   | 誰が持つか       | 参加者への配布                       |
|----------------------|----------------------------------------------------------------------------------------------------------------------|-------------|-------------------------------|
| C (匿名化データ)           | 各チームが B から作って提出する匿名化データ。採点と攻撃の対象。チーム $i$ のものを $C_i$ 。                                                                | 提出後は全チーム    | あり (攻撃フェーズで全チームの C が配られます)    |
| F (攻撃提出物)            | 攻撃側チーム $j$ が加工者 $i$ の $C_i$ に対して出す攻撃結果。対象ごとの答え。<br>MIA = メンバーである確からしさ (F_mia.csv)、<br>AIA = 伏せられた項目の推定値 (F_aia.csv)。 | 提出したチームと事務局 | なし (各フェーズの終了後に全提出物を公開 = §7.2) |
| MIA (メンバーシップ推論)      | ある個人が元データ $B_i$ に入っていたかどうかを当てる攻撃 (§4.1)。                                                                             | —           | —                             |
| AIA (属性推論)           | ある個人の、伏せられた項目の値を当てる攻撃 (§4.2)。本大会では「何年後に発症したか」を当てさせる。                                                                 | —           | —                             |
| U (有用性) / Anon (匿名性) | 匿名化データのできばえを測る 2 つの得点。どちらも 0~1 (1 が良い)。                                                                              | —           | —                             |

配られるのは背景データ  $A_{bg}$ ・自分の  $B_i$ ・ $B_{self}$ ・(攻撃フェーズでは) 全チームの C だけです。母集団 A そのものは配布しません。

## 1. 大会概要・目的

### 1.1 この競技の物語

あなたのチームは、**健診データを匿名化して売るスタートアップ企業**です。手元にあるのは、ある地域の住民の健診記録 (B) —— 年齢・血圧・血糖値から、10 年間の追跡でその人が糖尿病を発症したか、いつ発症したかまで並んだ個人データです。これをそのまま売ることはできません。個人が特定されない形に**匿名化したデータ (C)** を作って売るのが、あなたの仕事です。

あなたの顧客は研究者です。ひとは、集団全体の傾向を知りたい**疫学研究者** —— 「どんな人が糖尿病になりやすいか」「10 年でどのくらい発症するか」を、あなたのデータで分析します。もうひとは、数の少ない**非典型的な患者 (希少群)** を調べたい研究者 —— 若くして急に発症する特殊なタイプ (MODY・1 型) を、あなたのデータで分析します。だから、あなたの匿名化データは、**様々な分析で本物の代わりに使って同じ結論が出る**ことが求められます。集団の傾向も、発症の要因も、希少な患者の姿も維持しなければ、顧客の誰かが不満を持ちます。これが**有用性 (U)** です。

一方で、**同業他社（＝他チーム）はライバル**です。彼らはあなたの売った匿名化データ *C* を手に入れ、「実在する患者の情報を漏洩させているのではないか」と粗探しをします。もし、ある個人が元データに入っていたことを当てられたり（**メンバーシップ推論**）、伏せたはずの発症情報を当てられたり（**属性推論**）すれば、それを顧客に告げ口されて信用を失います。**攻撃されても個人が割れないこと**——これが**匿名性（Anon）**です。あなた自身も、他社のデータを攻撃する側に回ります。

この競技の**核心は、有用性と匿名性の綱引き**です。本物に近づけるほど有用性は上がりますが、実在の個人が透けて匿名性は下がります。逆に、安全にするために元のデータから乖離させすぎると顧客の役に立たなくなります。特に、もともと数の少ない希少な患者は、真っ先に消えてしまいます。**両方を同時に成り立たせられるかが問われます。**

## 2. スケジュール・エントリー

**参加者説明会**：2026-07-30（木）18：15～19：00。説明 30 分程度＋ Q&A15 分程度（詳細は別途案内）。当日の録画を後日公開します。

**構成**：予備戦→本戦の 2 ラウンド。各ラウンドは「加工フェーズ（匿名化データを作る）」→「攻撃フェーズ（他チームを攻撃する）」の順。各フェーズは 14 日間。

| 期間                 | 日程                 |
|--------------------|--------------------|
| 練習（CodaBench 練習環境） | 7/30（木）～ 8/8（土）    |
| 予備戦・加工フェーズ         | 8/9（日）～ 8/22（土）    |
| 予備戦・攻撃フェーズ         | 8/25（火）～ 9/7（月）    |
| 本戦・加工フェーズ          | 9/12（土）～ 9/25（金）   |
| 本戦・攻撃フェーズ          | 9/28（月）～ 10/11（日）  |
| 発表・表彰（CSS2026・浜松）  | 10/19（月）～ 10/23（金） |

**エントリー**：説明会（7/30）から予備戦終了まで受け付けます。Web サイトから参加登録。予備戦加工フェーズ中の参加登録は即時参加、攻撃フェーズ中の参加登録は本戦加工フェーズ開始時の参加になります。

**チーム構成**：原則 5 人以下とし、一人が複数チームに所属することはできません。チームに所属するメンバー全員を参加登録時に報告してください。チーム外の人との直接的な関与は望ましくありません。

**代表者**：チームメンバーのうち一人が代表者となり、チーム登録を行なってください。チーム代表者は競技プラットフォームである [CodaBench](#) のアカウントを作成し、チーム登録時に申告してください。すでにアカウントを所有している場合はそれを申告しても構いません。代表者が離脱した場合、競技参加も事務局からの連絡もできなくなる可能性があります。

**発表義務**：少なくとも各チームの代表者は、CSS2026（10/19～10/23・浜松）に参加登録し、CSS2026 内の PWS Cup セッションで現地発表（ポスターおよびプレゼンテーション）を行ってください。旅費と参加登録費が必要になりますので、参加を決める前に見込んでおいてください。現地発表が難しい場合は事務局までご相談ください。なお、現地で発表しても、大会 Web サイト等での氏名・所属の公開は下記のとおり任意です。

**匿名参加**：各参加者は、後述する例外を除いて、自身の氏名と所属を公開する義務はありません。公開を希望するチームだけは web サイトで代表者の氏名と所属の片方または両方を公開します。

**責任者と指導者：**学生主体のチームは責任者（准教授や教授を想定）を必ず設定してください。さらに任意で、指導者（外部メンターや助教を想定）もチームに加えることができます。これら2つの役職は上記の5人に含めません。つまり、学生主体のチームは最大7人にすることを認めます。責任者と指導者は学生の教育効果を高めるために監督や助言を行うことを意図した役職であり、競技への直接的な関与は望ましくありません。責任者と指導者は複数チームで兼務できますが、兼務した場合は氏名・所属を必ず公開します。また、責任者と指導者は別のチームの通常参加者にはなれません。競技の公平性の調整と学生の教育効果の最大化を意図したルールです。責任者と指導者はルールの意図を尊重し、通常参加者以上に公平性に対する高い意識を持ってください。

**チームメンバーの変更：**チーム登録後、メンバーが別チームに移籍することはできません。4名以下のチームへの完全新規メンバーの追加に限り、ワーキンググループに相談のうえ認めます。「5人チームだったのに、4人蒸発した」というケースは今回の競技の設計上、救済することが難しいです。誰と組むのかチーム登録前によく考えてください。

---

### 3. データ仕様

- **題材：**健診の縦断データ・発症前の母集団。複数の公開データを参考に構築。多数派は発症前の受診者（10年で約7～10%が2型糖尿病を発症）。
- **希少群：**母集団のなかで、非典型的な発症をする少数の患者。若年・急進で発症する **MODY (HNF1A型)** と **1型糖尿病** の2つを、本ルールブックではこれらを希少群の「型（タイプ）」と呼びます（多数派の2型糖尿病とは別のタイプです）。成人発症の緩徐進行型（LADA）は1型の裾として扱い、独立の型は設けていません。
- **配布形式：**単一表（1人1行）。 $B$  の列は record\_id・age・sex・prefecture・BMI・SBP・TG・HDL・ALT・smoking・FPG・time・onset・death。また、自チームの自己採点用の補助情報を含む  $B\_self$  は加工フェーズで配ります。§5.4)。
- **打ち切り・死亡：**10年たっても発症しない人、発症前に亡くなる人もいます。ただし糖尿病の発病と死亡の間には関連がないものとしてデータを生成しています。
- **規模：**用意したコホートは **30 セット**（この本数を  $N$  と書きます）で、これが参加できるチーム数の上限です（20チーム前後を見込んでいます）。1チームに配られるコホート  $B_i$  は **1,049 人**、そのうち希少な患者は **24 人（2.3%）** —— 内訳は MODY (HNF1A 型) **17 人**・1型糖尿病 **7 人**です。この4つの数は全チームで厳密に同じで、予備戦・本戦でも変わりません。なお、30を超える申込みがあった場合は、コホートを作り直して  $N$  を増やします。その場合は、**新しい  $N$  を salt の公表より前にお知らせします** (§3.2)。30に達しないかぎり  $N$  は30のまま動かしません。この作り直しは、予備戦開始直前および本戦開始直前にだけ発生する可能性があります。フェーズ途中のデータ再生成・再配布は行いません。
- **転帰の出方：**追跡は最長10年。10年のあいだに発症する人はおよそ **1割**、発症前に亡くなる人が **7～8%** です（データを作り直すたびに1ポイント程度は動きます）。**希少群の発症率は多数派よりずっと高く、多数派が約1割なのに対して希少群は3～4割が発症します。**

#### 3.1 コホートの構造（非共有ブロック $P_i$ と共有ブロック $S_{ij}$ ）

あなたのチームに配られるコホート  $B_i$  は、性質の違う2種類の行が混ざってできています（図2）。同じ人が2つのチームのコホートに入っていることがある、というのがこの競技の総当たりの肝です。

- **母集団はひとつ**：全チームのコホートは、ひとつの母集団 A から切り出したものです。だから全チームのデータは無関係ではなく、傾向は似ています。ただし後述のとおりチームごとに県に見立てた意図的な偏りを持たせており、同一の分布からの独立標本 (i.i.d.) ではありません。
- **非共有ブロック  $P_i$  (あなただけの行)**：あなたのチームにだけ配られ、他のどのチームとも共有しない行です。割り当てられた県（地元）の人口構成に従うので、ここがチームごとの分布の違いを担います。**属性推論攻撃 (AIA) の標的  $T_i$  はここから取ります。**
- **共有ブロック  $S_{ij}$  (他チームと同じ人)**：あなたのチーム  $i$  と別のチーム  $j$  が、同一の個人を共有している行です ( $S_{ij} = B_i \cap B_j$ )。同じ人が 2 チームのコホートに入っている — これが**メンバーシップ推論 (MIA)** の標的です。攻撃者は「自分のコホートにいるこの人は、相手のコホートにもいるか？」を当てにきます。
- **各チームのコホートのまとめ**： $B_i = (\text{非共有ブロック } P_i) + (\text{他の全チームとの共有ブロック } S_{ij} \text{ の和})$ 。希少な患者は、どの型も、非共有・共有の両方のブロックに配置します。
- **人数の内訳**： $B_i$  の 1,049 人のうち、**あなただけの行 (非共有ブロック  $P_i$ ) が 313 人、他の 29 チームと共有している行 (共有ブロック  $S_{ij}$  の合計) が 736 人**です。1 チームあたりの共有ブロックは 25~27 人 (希少な患者を各チームに均等配分する都合で、組ごとに 1~2 人の差が出ます)。**313 人と 736 人という内訳も全チームで厳密に同じです。**
- **開示しないこと**：どの行が  $P_i$  でどの行が  $S_{ij}$  か (どのチームと共有しているか) は、参加者には開示しません。割り当ての真値は事務局のみが持ちます。自チームの  $B_i$  のどの行が希少群であるかは  $B_{i,\text{self}}$  という拡張データに記述されています。他チームの  $B_{i,\text{self}}$  は開示しません。

## 図2：コホート $B_i$ の構造

1つの母集団 A から切り出した、あなたのチームのコホート  $B_i$ 。性質の違う2種類の行でできている。




図1 図2：コホート  $B_i$  の構造。あなただけの行 (非共有ブロック  $P_i$  = 属性推論 (AIA) の標的) と、他チームと同じ個人を含む共有ブロック  $S_{ij}$  (メンバーシップ推論の標的) からなる。

図2：コホート  $B_i$  の構造

### 3.2 配布の公平性の担保

- **行数をそろえる**：全チームの  $B_i$  は行数が厳密に同じです。
- **希少な患者の数と型をそろえる**：希少群は型ごとに全チームへ均等に配ります（どの型の希少患者も、各チームに同じ数だけ）。さらに、**そのうち実際に発症した人の数も全チームで同じになるように配分**します。攻撃されたときの当てられやすさが、配られた患者の内訳によって変わらないようにするためです。
- **背景データの構成**：全チームに配る背景データ  $A_{bg}$  は、皆さんのコホートと同じ割合で希少な患者を含みます。背景データだけ希少が多い、といった偏りは持たせていません。
- **共有ブロックの中の希少もそろえる**：総当たり表の組み方を工夫して、各チームが共有する希少な患者の数・型を厳密にそろえます（チームごとに配られる希少な患者の構成が同一）。ただし、各共有ブロック単位では希少患者数に 1～2 の差がある場合があります。
- **外れ度バンド**：外れ度＝各レコードのマハラノビス距離（多数派＝2 型群の分布からの距離）。希少な患者はこの距離が大きくなります。これを目標の帯に較正し、特定チームだけ「守りにくい希少」に偏らないようにします。
- **ハッシュ割当 + salt**：どの  $B_i$  をどのチームに配るかは、次の手順で機械的に決めます。事務局にも参加者にも、狙ったデータを引き寄せる余地はありません。
  1. 事務局が salt（かく乱用の文字列）を決め、**そのラウンドのデータ配布時に公表**します。salt は予備戦と本戦で別のものを使います（同じにすると、両ラウンドで全チームが同じ番号を引いてしまい、「独立 2 ラウンドで引きの差を平均化する」という下の項目の意味が無くなるため）。
  2. 各チームについて  $\text{key} = \text{SHA-256}(\text{チーム名} \parallel \text{salt})$  を計算します（ $\parallel$  は文字列の連結）。key は 64 桁の 16 進数です。
  3. key を整数とみなして  $\text{番号} = \text{key} \bmod N$  を求めます。これが、そのチームに配る  $B$  の番号です。 $N$  は用意したコホートのセット数＝30（§3 の規模）。**エントリー開始前にこのルールブックで公表済みで、あとから変えることはしません。**
  4. その番号がすでに別のチームで埋まっていたら、空いている番号が見つかるまで番号を 1 つずつ進めます（ $N$  を超えたら 0 に戻ります）。チームの処理順は登録順です。30 枠に 20 チーム前後なので番号がぶつかること自体はよくありますが、枠はチーム数より多いので必ず空きが見つかります。先に登録したチームの番号は、あとから誰が登録しても動きません（エントリーは競技期間中ずっと開いているため、この性質が要ります）。

**なぜこれで操作できないのか。**SHA-256 は、入力が 1 文字違うだけで出力がまるごと変わり、出力から狙った入力を逆算できない一方向の関数です。salt は配布時まで伏せられているので、参加者が「あのデータが当たるチーム名」を狙って付けることはできません。事務局の側も、 $N$  は事前に公表済み・チーム名は登録で決まっているので、あとから動かせるものが残っていません。

**どう検証するか。** salt が公表されたあとは、各チームが自分で key を計算し直せます。手元で SHA-256(チーム名  $\parallel$  salt) を求め、それを 30 で割った余りが配られた番号（または、そこから順に進めた最初の空き番号）と一致することを確認できます。チーム名は Unicode の NFC 正規化をしてから連結してください（濁点などが合成済み文字か結合文字かで別の値になるため）。

なお、そもそも  $B_i$  同士は上の各項目（行数・希少の数と型・発症した人数・外れ度の帯）でそろえてあるので、どれが当たっても有利不利は生じないと期待されます。この割当は、その上でさらに「誰かが恣意的

に配布データを選んだのではない」ことを目に見える形にするためのものです。

- **独立 2 ラウンド**：予備戦・本戦を独立のデータで実施し、外れ値の引きの差を平均化します。
  - **開示範囲**：参加者へは等質な集計分布のみ開示します（各チーム同数・同型・同じ外れ度帯）。どのチームとどのチームがどの行を共有しているかは開示しません。各チームは  $B_i$  および  $B_{i,\text{self}}$  が他チームに漏洩しないように、セキュリティに十分配慮してください。Github の public レポジトリや他チームもアクセス可能な研究室共有サーバーには配置すべきではありません。提出した  $C_i$  に対する攻撃フェーズの正規の活動以外で漏洩が発生した場合は、関与したチームが不正行為をしたものとみなす場合があります。意図的かどうかによらず、不正をしない・させないことを心がけてください。
- 

## 4. 競技フロー

- **加工フェーズ**：配布された  $B_i$  を匿名化し、 $C_i$  を作って提出します。
- **攻撃フェーズ**：全チーム総当たり。他チームの  $C_i$  に攻撃します（自分のチームは攻撃しません）。**各チームは、他の全チームに対する攻撃結果  $F$  を一括で提出します。** $F$  はメンバーシップ推論（MIA）と属性推論（AIA）の 2 種類の結果で構成されます。
- **答える相手は「実際に参加しているチーム」だけです**：コホートは 30 セット用意してありますが、実際に配るのは参加チームのぶんだけです。攻撃の対象になるのも、**その回に参加している、自分以外のチーム**だけ。誰が対象なのかは、攻撃フェーズの配布物 `mia_columns.json`（その回の対象チーム ID が並んだファイル）に書いてあります。存在しない ID に答える必要はありません（答えても採点されません）。以下では対象チームの数を「他の全チーム」と書きますが、実際の数に参加チーム数から 1 を引いたものです。

### 4.1 攻撃①メンバーシップ推論（MIA）

- **問い**：ある個人が加工者  $i$  の元データ  $B_i$  に含まれていたか。攻撃者  $j$  は、自分のコホート  $B_j$  の各個人について、それが  $B_i$  にも含まれる（共有ブロック  $S_{ij}$  に入る）確からしさを 0~1 で答えます。
- **提出**：行＝自分のコホートの候補、列＝対象チームの確信度を並べた `F_mia.csv` 1 枚（様式は §5.2）。
- **規模**：答える候補は、自分のコホートの **1,049 人すべて**です。そのうち相手チームとも共有している人（＝正解）は **25~27 人**、つまり **2.4% 程度**しかありません。他の 29 チームぶんを一括で提出するので、`F_mia.csv` は **1,049 行 × 30 列**（`record_id` + 対象 29 チーム）＝約 **3 万セル**になります。
- **攻撃の実装例**：密度比  $p_{\text{syn}}/p_{\text{ref}}$ （ $p_{\text{syn}}$  = 匿名化データ  $C_i$  上の密度・ $p_{\text{ref}}$  = 背景データ  $A_{\text{bg}}$  上の密度）を連続共変量で推定し、比が高い個人ほど「 $B_i$  のメンバー」と判定。この実装例を配りますが、攻撃方法を縛るものではなく、独自の攻撃を使ってかまいません。
- **考え方**：MIA は元データの行をそのまま残す  $C$  に対しては成功しやすいです。（採点の式は §6.2.1。）

### 4.2 攻撃②属性推論（AIA）

- **問い**：加工者  $i$  の非共有ブロック（他チームと共有しない、そのチームだけが持つ実在の個人）から選ばれた人について、伏せられた「**追跡年数**」——その人が何年後に糖尿病を発症したか（発症しなかった人は最長 10 年）——を当てられるか。
- **`aia_challenge_<k>.csv` が配られます**：対象チームごとに 1 枚（`<k>` は対象チームの ID）。1 行が 1 人で、各人の一部の列だけが入っています——`challenge_row_id`・`age`・`SBP`・`TG`・`HDL`・`ALT`・`sex`・`prefecture`

の 8 つ。追跡年数 (time) と発症の有無 (onset) は入っていません (伏せてあります)。答えは事務局だけが持っています。

- `aia_challenge_<k>.csv` の半分は、そのチームのデータに入っていない別人です：行は次の 2 種類で、同数です。

- 標的：対象チームの非共有ブロックにいる実在の個人。事務局がランダムに選びます。
- 対照：対象チームのコホートにも、他のどのチームのコホートにも、背景データ  $A_{bg}$  にも入っていない別人。標的 1 人につき対照 1 人を、県・性別・年齢帯・発症の有無をそろえて選んであります。

2 種類は `aia_challenge_<k>.csv` の中でシャッフルされていて、攻撃者にはどちらがどちらか分かりません。全行に同じように答えてください。事務局は答え合わせのときだけ 2 つに分け、標的での正解率と対照での正解率を別々に出します。なぜ対照を混ぜるのかは §6.2.2 で説明します (ひとことと言うと、「そのチームのデータを見なくても当たってしまう分」を差し引くためです)。

- 攻撃者が出すもの：`aia_challenge_<k>.csv` の各行について、対象チームの匿名化データ  $C_i$  を手がかりに、その人の追跡年数を推定した数値 `time_hat` (年数そのもの。確信度ではありません) を答えます。提出するのは `F_aia.csv` 1 枚だけで、対象チームごとにファイルを分けません。1 行が「どの対象チームの・`aia_challenge_<k>.csv` の何行目に・何年と答えたか」を表し、列は `target_k` (対象チームの ID)・`challenge_row_id` (`aia_challenge_<k>.csv` の行 ID)・`time_hat` の 3 つ。全対象ぶんの回答を、この形で縦に積み上げた 1 枚にします (様式は §5.2)。
- 規模：`aia_challenge_<k>.csv` は 1 枚あたり 326 行 (標的 163 人 + 対照 163 人)。標的 163 人のうち、10 年以内に発症した人は 16 人、希少な患者は 13 人 (そのうち発症した人が 4 人) です (この内訳も全チームで同じです。対照も標的と 1 対 1 でそろえてあるので、同じ内訳になります)。対象が 29 チームなら `F_aia.csv` は 9,454 行になります。
- なぜ当てられてしまうのか：加工側チームが、ある人の行をほぼそのまま  $C_i$  に入れていけば、渡された 8 列で  $C_i$  の中の「同じ人」を見つけ、そこに書かれた追跡年数を読むだけで当たります。一方、実在の個人をそのまま残さずに作ったデータからでも、似た人たちの平均的な傾向からある程度は当たります。ただしそれは、そのチームのデータを見なくても言えることなので、対照でも同じくらい当たります。∴採点で見るのは、標的での正解率が対照での正解率をどれだけ上回ったかだけです (§6.2.2)。
- 攻撃の実装例：連続する検査値 `[age・SBP・TG・HDL・ALT]` で  $C_i$  の最近傍を 1 件引き、その行の追跡年数を `time_hat` とする。この実装例を配りますが、独自の攻撃を使ってかまいません。

---

## 5. 提出物・フォーマットと自己採点

### 5.1 加工提出 C

配布と同じ単一表 (1 人 1 行) で提出します。次の 3 つを満たしてください。

- すべてのセルが具体的な 1 つの値で埋まっていること。欠測で伏せる (suppression) ことも、「40~50」のように範囲で表す (generalization) ことも認めません。
- 各列の値が、その列に許された範囲 (値域) に収まっていること。値域とは、列ごとに定めた「取ってよい値の範囲」です (例：sex は  $\{0, 1\}$  のいずれか (0/1 の二値)、FPG などの検査値は生理的にありうる下限~上限の範囲)。具体的な値域は、配布データ・スターターキットに同梱します。範囲を外れる値は受け付

けません (§5.5)。

- `record_id` は削除し、行数は元データ *B* と完全に一致させること (1,049 行)。

補足：

- *k*-匿名化などで値を伏せたいチームは、伏せたセルを自分で補完してから提出してください (採点を欠測なしに保つのが最も確実なためです)。
- 行数を一致させるのは、「行を減らして薄めると匿名性だけ安く上がる」抜け道を封じるためです。

## 5.2 攻撃提出 F

攻撃は 1 回の提出で、`F_mia.csv`・`F_aia.csv`・`token.txt` の 3 つを **zip** の直下 (フォルダを作らず) に入れて出します。

- `F_mia.csv` (1,049 行 × 30 列)：行＝自分のコホートの `record_id`、列＝攻撃対象チームの ID。各セルは「この人はその相手の元データに入っていたか」の確信度 (0~1)。行は配布された `record_id` と過不足なく一致させ、自分のチーム以外のすべての対象に答えてください (対象チーム ID は `mia_columns.json` にあります。列の欠落があると受け付けません)。
- `F_aia.csv` (対象が 29 チームなら 9,454 行 = 326 行 × 29 対象)：1 行が「どの対象チームの・`aia_challenge_<k>.csv` の何行目に・何年と答えたか」を表す形式で、列は `target_k` (対象チーム ID)・`challenge_row_id` (`aia_challenge_<k>.csv` の行 ID)・`time_hat` (推定した追跡年数。確信度ではなく年数そのもの) の 3 つ。配布された `aia_challenge_<k>.csv` の全行に 1 行ずつ答え、自分のチーム以外のすべての対象を出してください。
- `token.txt`：登録時に配られたあなたの秘密トークンを 1 行だけ。チーム名や ID は書きません。

形式・値域・過不足は提出時に検証し、外れていれば採点しません (§5.5)。

## 5.3 提出できる回数

提出して自分の得点を確かめられる回数は、フェーズごとに異なります。

- **加工フェーズ**：無制限。匿名化データ *C* は何度でも出し直し、得点を見ながら作り込んでもかまいません。
- **攻撃フェーズ**：8 回まで。攻撃提出 *F* を採点に出せるのは最大 8 回です。限られた採点結果から情報を慎重に読み取り、次にどんな攻撃をするのか考えてください。無制限の提出を認めると、匿名化データを全く使わずに採点結果だけから攻撃できてしまうため、提出可能回数を少なめにしています。

## 5.4 ローカル環境での自己採点

後述するスターターキットに含まれる採点プログラムで、参加者はローカル環境で有用性の自己採点ができます。CodaBench での採点と同じ点数になりますが、ローカル環境での採点の方が CodaBench の web 操作などが不要な分、採点と改善のループが回しやすいと思います。

実行環境の違いで CodaBench での採点とローカル環境での採点で点数がズレる可能性があります。この場合は CodaBench での点数を公式記録として採用します。このようなズレがあった場合は事務局まで報告していただくと助かります。

自己採点では、*U* だけでなく 4 つの観点 ( $U_{\text{gen}} \cdot U_{\text{spec}} \cdot U_{\text{rare}} \cdot U_{\text{valid}}$ ) の内訳まで出ます。*U* はこの 4 つの最小値なので、一番低い内訳を見れば、どこを直せば得点上がるかが分かります。希少と判定された行数など、点数

が 0 になった理由の診断も出ます。

## 5.5 提出時フォーマットチェック

フォーマットと値域を提出時に検証し、外れていれば**採点しません**。この場合、その提出は CodaBench 上で**失敗 (Failed)** として記録され、**提出回数には数えません**。何が悪かったかは提出の詳細結果に出ます。

## 5.6 リーダーボードの見方

リーダーボードは 6 列です。加工の提出と攻撃の提出が同じ表に並ぶので、列の中身は提出の種類で変わります。

| 列    | 加工（防御）の提出                            | 攻撃の提出                        |
|------|--------------------------------------|------------------------------|
| 得点   | <b>有用性 <math>U</math></b> （この列で並びます） | <b>攻撃力合計</b> （MIA 力 + AIA 力） |
| 内訳 1 | $U_{\text{gen}}$                     | MIA 攻撃力（全体）                  |
| 内訳 2 | $U_{\text{spec}}$                    | MIA 攻撃力（希少）                  |
| 内訳 3 | $U_{\text{rare}}$                    | AIA 攻撃力（全体）                  |
| 内訳 4 | $U_{\text{valid}}$                   | AIA 攻撃力（希少）                  |
| 保護   | protection                           | —（該当なし・空欄）                   |

有用性  $U$  は内訳 1～4 の最小値です (§6.1)。つまり、**最も低い内訳がそのまま得点**になります。どこを直せば得点上がるかがリーダーボード上でそのまま読めるので、まず一番低い内訳を見てください。

「保護 (protection)」は、事務局が用意した決まった攻撃を 1 本だけ、あなたの匿名化データに当てた速報値です (1 - その攻撃の成功度)。読み方に 3 つ注意してください。

- 最終得点の匿名性とは別物です。§6.2 の匿名性は、全参加チームの攻撃が出そろってから締切後に集計して決まります。加工フェーズの保護はその予告でも近似でもありません。
- 1.00 でも本番で安全とは限りません**。決まった攻撃 1 本に対する値なので、その攻撃だけをかわす作り方をすれば簡単に上がります。逆に、値が低いときは「実在の個人がそのまま残っている」サインとして使えます。
- 順位づけには**使いません**。総合順位は  $\min(U, \text{Anon})$  (§6.0) だけで決まります。リーダーボードの並び順も「得点」の列だけで決まります。

加工フェーズの時点では他チームの攻撃がまだ存在しないため、匿名性の手がかりを何も返さないと、有用性だけを見て作り込むことになってしまいます。その代わりの粗い目安、という位置づけです。

## 6. 採点方式

### 6.0 採点の全体像

各チームは「匿名化データを作る側（加工者）」と「他チームの匿名化データを攻撃する側」の両方を行います。得点は次の 2 本立てです。

- 総合順位 = 有用性  $U$  と 匿名性 **Anon** の 2 軸で決まる。

- **攻撃力（ベストアタック賞）**＝攻撃の強さによるサブランキング。どのくらい敵チームの匿名得点を下げられたかを競う。

総合得点は次の一本の式で与えます。

$$\text{総合得点} = \min(U, \text{Anon})$$

$U$  も  $\text{Anon}$  も 0～1（1 が良い）。 $\min$  なので、**弱いほうの軸がそのまま得点**になります。

**なぜ  $\min$ （足し算でなく）か。**有用性と匿名性は互いに引っ張り合います——元データの個人をそのまま残すほど本物に近づいて有用性は上がりますが、そのぶん誰が含まれていたかが分かりやすくなり匿名性は下がります。 $\min$  は弱いほうがそのまま得点になるので、どちらかを犠牲すると高得点は取れません。

## 6.1 有用性 $U$ （4 つの観点の最小）

有用性は次の 4 つの観点で測ります（自己採点や詳細結果の出力では **facets** と表記されます）。各観点は 0～1（1 が良い）。まとめ方は **4 つの最小値**です。一番低い観点が、そのまま有用性になります。

$$U = \min(U_{\text{gen}}, U_{\text{spec}}, U_{\text{rare}}, U_{\text{valid}})$$

| 記号                 | 名前                            | 何を測るか                       |
|--------------------|-------------------------------|-----------------------------|
| $U_{\text{gen}}$   | 一般有用性（gen = general）          | データ全体の分布が本物にどれだけ似ているか       |
| $U_{\text{spec}}$  | 特定タスクでの結果忠実度（spec = specific） | 「何が発症に効くか」の分析結果が本物と同じ結論になるか |
| $U_{\text{rare}}$  | 希少群の有用性（rare）                 | 希少群（非典型糖尿病）を潰さず再現できているか     |
| $U_{\text{valid}}$ | 妥当性（valid = validity）         | 数値だけ取り繕う小細工を防ぐ最低限の整合チェック    |

**4 つの観点は同じ重みで、その最小値をとります。**どれか 1 つでも低ければ、他がどれだけ高くても有用性はそこで頭打ちになります。たとえば全体の分布が本物そっくり（ $U_{\text{gen}}$  が高い）でも、希少な患者（非典型糖尿病）を潰していれば  $U_{\text{rare}}$  が下がり、有用性はそこで決まります。発症の分析結果（ $U_{\text{spec}}$ ）を崩しても、値の整合（ $U_{\text{valid}}$ ）を崩しても同じ。**得意な観点で稼いで苦手な観点を埋め合わせることはできません**——4 つの観点すべてでそこそこの点数をとることを求める設計です。

**作るときの勘どころ：**4 つのうち一番低い観点が有用性を決めます。 $\text{Anon}$  を上げるために希少群を消す、発症の因果構造を壊すなどアドホックな操作をした場合には簡単に点数が下がるように設計しました。

### 6.1.1 $U_{\text{gen}}$ 一般有用性 = $\min$ (周辺分布, pMSE, 発症曲線)

#### 測り方

3 つの相補的な観点の**最小値**。 $U_{\text{gen}} = \min(\text{marginal}, \text{pMSE}, \text{time\_dz})$ 。

- **周辺分布の一致 (marginal)**：各列の分布が本物にどれだけ近いか。連続列は  $1 - \text{KS}$  ( $\text{KS} = 2$  つの分布の最大のズレ、 $0 \sim 1$ )、カテゴリ列は  $1 - \text{TVD}$  ( $\text{TVD} = \text{各カテゴリの割合差の合計}$   $\frac{1}{2} \sum_k |p_k^C - p_k^B|$ ) を列ごとに出し、**10 列の平均** (連続 7 列 = age · BMI · SBP · TG · HDL · ALT · FPG と、カテゴリ 3 列 = sex · smoking · prefecture。time · onset · death の分布はここでは見ません＝発症の時間的な出方は下の time\_dz で別に見ます)。
- **pMSE (同時分布の一致)**：本物と匿名化データを混ぜ、判別器 (ロジスティック回帰) に「どちらのデータか」を当てさせます。各行が匿名化データである推定確率を  $\hat{p}$ 、匿名化データの割合を  $c$  ( $|C| = |B|$  ゆえ  $c = 1/2$ ) として  $\text{pMSE} = \text{clip}(1 - \frac{\text{mean}(\hat{p}-c)^2}{c(1-c)}, 0, 1)$ 。対象は主要 9 列 (連続 7 列 + sex · smoking。prefecture と time · onset · death は含めません)。
- **発症曲線の一致 (time\_dz)**：まだ発症していない人の割合が時間とともにどう減るかの曲線  $S(t)$  の一致。本物  $S_B$  と匿名化データ  $S_C$  の差の面積を、本物の発症の大きさ  $D_B = \int (1 - S_B) dt$  で正規化します。この差の面積からは、まず「 $B$  という標本そのもののばらつきで生じる分」( $B$  を 2 回ブートストラップした発症曲線どうしの差を積分し、その分位点を取った値) を差し引いてから正規化します＝この分までは標本の揺らぎとみなして無罰にします。

## 意味

3 つはそれぞれ別の壊れ方を見ている — **周辺分布＝各列を単体で／pMSE＝列どうしの絡み／発症曲線＝時間の出方**。pMSE は本物と見分けがつかないほど高得点になり、同時分布が本物に近いことを表します。最小値をとるので、どれか 1 つでも低ければ、そこが  $U_{\text{gen}}$  になります。

### 6.1.2 $U_{\text{spec}}$ 特定タスクでの結果忠実度 = min(結論一致, 判別再現)

#### 測り方

本物  $B$  と匿名化データ  $C$  のそれぞれで、9 つの共変量 (age · sex · BMI · SBP · log TG · HDL · log ALT · FPG · smoking) → 発症の多変量 cause-specific Cox (死亡は打ち切り扱い) を学習し、次の 2 つの最小値をとります。  
 $U_{\text{spec}} = \min(\text{IO}, \text{tstr\_cal})$ 。

- **結論一致 (IO = Interval Overlap, 信頼区間の重なり)**：9 係数それぞれの寄与を平均します。1 係数の寄与は —
  - 有意 (信頼区間が 0 を除外) かどうかは本物と匿名化データで食い違えば 0 点。
  - 両方が有意でも 符号が逆なら 0 点。
  - それ以外は 信頼区間の重なり の割合：本物の区間  $[\ell_B, h_B]$  · 匿名化データの区間  $[\ell_C, h_C]$  の重なり幅を  $o = \min(h_B, h_C) - \max(\ell_B, \ell_C)$  として  $\frac{1}{2}(\frac{o}{h_B - \ell_B} + \frac{o}{h_C - \ell_C})$  ( $0 \sim 1$ )。
- **判別再現 (tstr\_cal = Train on Synthetic, Test on Real)**：上と同じ 9 つの共変量から「発症の起きやすさ」を予測する Cox モデルを、匿名化データ  $C$  だけで学習し、その学習済みモデルを本物  $B$  に当てて、発症が早い人ほど高リスクと予測できているか (発症の順序をどれだけ正しく当てられるか＝判別性能 · concordance · c-index) を測ります。同じことを本物  $B$  で学習して本物  $B$  で測った値  $c_{\text{TRTR}}$  で割って較正します。 $\text{tstr\_cal} = \text{clip}(\frac{c_{\text{TSTR}} - 0.5}{c_{\text{TRTR}} - 0.5}, 0, 1)$  ( $0.5 = \text{順序をまったく当てられていない状態}$ )。
  - 本物データ自体に予測できる構造がほとんど無い ( $c_{\text{TRTR}}$  が 0.5 に近い) ときは較正の分母が小さくなりすぎて不安定なので、その場合は  $\text{tstr\_cal} = 1$  とします。
- **推定が成立しないデータは 0 点**：匿名化データが偏りすぎると、この Cox 回帰そのものが成り立たないことがあります (例：発症した人が 1 人もいない／ある項目の値が全員同じ／ある項目の値だけで発症の有無が完全に決まる [完全分離])。こうした極端なデータは  $U_{\text{spec}}$  を 0 点とします。採点の Cox は正則化を用いない素の推定です。

## 意味

「匿名化データで疫学分析をしたら、本物と同じ結論に至るか」を測ります。**結論一致**が見ているのは「何が発症に効くか」という**解釈が変わらない**かで、「本物で効く要因を消した（見逃し）」も「本物で効かないのに有意にした（偽陽性の捏造）」も、両方を等しく罰します。**判別再現**が見ているのは**予測に使える構造が残っている**かで、 $c_{\text{TRTR}}$  で割るのは「本物データで作れば届く上限」を満点の基準にするためです。つまり匿名化データで学習しても、本物で学習したのと同じくらい発症を当てられれば満点という意味になります。分析が成立しないデータが有用なはずはないので、Cox が立たないケースは 0 点としています。正則化を使わないのは、参加者が手元の素の Cox で検算した結果と採点を一致させるためです。

### 6.1.3 $U_{\text{rare}}$ 希少群の有用性 = min(希少率, プロファイル, 発症, 同時分布)

#### 測り方

4 つの観点の最小値。  $U_{\text{rare}} = \min(\text{mass\_star}, \text{prof\_cal}, \text{onset\_cal}, \text{c2st\_cal})$ 。

- **希少率 (mass\_star)**：各行が多数派の分布からどれだけ外れているかをマハラノビス距離で測り、一定以上外れて「希少」とみなせる行の割合を、本物  $m_B$ ・匿名化データ  $m_C$  で比べます。データ生成時のランダムさに由来する誤差は差し引いています。
- **プロファイル (prof\_cal)**：希少な患者を特徴づける各項目（年齢・各検査値など）の分布が本物とどれだけ一致しているか＝各項目の  $1 - \text{KS}$  の平均。
- **発症 (onset\_cal)**：希少群の発症率（発症した割合  $\bar{o}$ ）の一致。  $\text{clip}(1 - |\bar{o}_C - \bar{o}_B|, 0, 1)$ 。
- **同時分布 (c2st\_cal)**：希少群の同時分布（項目間の絡み合い・裾の依存）の一致。匿名化データの希少群と本物の希少群を判別器（ランダムフォレスト）で見分け、その AUC から  $\text{clip}(1 - 2|AUC - 0.5|, 0, 1)$ （判別不能＝AUC 0.5＝一致で 1）。

較正と希少判定の規則は次のとおりです。

- 末尾 \_cal の 3 つ（プロファイル・発症・同時分布）は、本物のデータをそのまま出したときでも標本のばらつきのせいでピッタリ一致にはなりません。そこで**本物のデータ自身で測った値を「満点の基準」（自己ベースライン）**とし、その基準で割って較正します（元データをそのまま出せば 1 になります）。
- 希少かどうかの判定は、比べる左右で少し異なります。 $C$ （あなたの提出データ）側では、多数派の分布からのマハラノビス距離が一定以上の行を「希少」とみなして**検出**します。 $B$ （本物）側の基準は、プロファイル・発症・同時分布の 3 指標では事務局が持つ**真の希少ラベル**を用い、外れ率（mass\_star）だけは  $C \cdot B$  とも検出ベースで測ります。
- あなたの提出データ  $C$  の中で希少と判定される行が **8 人**（同時分布の検証に要する人数）に**満たない場合**、希少群の**同時分布の忠実度を検証できないためその観点は 0 点**となり、 $U_{\text{rare}}$  は 4 つの最小値なので  $U_{\text{rare}}$  も 0 になります（本物  $B$  に十分な希少がいる限り）。プロファイルと発症の 2 観点は 3 人から評価しますが、同時分布が 0 になるため結果は変わりません。提出前に、スターターキットの検証器で自分の  $C$  の希少検出件数を確認できます。

#### 意味

希少群（外れ値＝非典型糖尿病）を潰す匿名化データを罰します。4 つはそれぞれ、**どれだけ居るか（希少率）／どんな人たちか（プロファイル）／どうなったか（発症）／項目どうしの関係まで再現できているか（同時分布）**を見えています。希少な患者をまるごと消す作戦は希少率で縛られ、分布をただなめらかにならしただけの匿名化は希少群の同時分布をうまく再現できません。

### 6.1.4 $U_{\text{valid}}$ 妥当性 = mean(打ち切り整合, 関係の非捏造)

#### 測り方

2つの平均。 $U_{\text{valid}} = \text{mean}(\text{cens}, \text{no\_fab})$ 。

- **打ち切り整合 (cens = censoring、打ち切り)**：発症も死亡もしていない人が、追跡打ち切り時刻  $H$  (horizon) になっているか。
- **関係の非捏造 (no\_fab = no fabrication、捏造なし)**：「群 → 指標」の関係を、匿名化データが本物より強めた分だけを減点します（強めた側だけを見ます）。ここで見る組は、群＝県・性別・喫煙、指標＝BMI・SBP・TG・HDL・ALT・FPG・発症 (onset) の21通り。各組について、群ごとの平均のばらつき（群の人数で重みをつけた標準偏差）を、その指標の  $B$  での標準偏差で割った値を「関係の強さ」とし、 $C$  と  $B$  で比べます。測る前に、 $C$  のその指標の値は  $B$  での最小値・最大値で頭打ちにします（範囲外の値は捨てるのではなく、境界の値に置き換えます）。ここでいう最小値・最大値は、 $B$  に実際に入っている値の上端・下端です。提出時の値域チェック (§5.1) が見る「生理的にありえる範囲」とは別のもので、こちらのほうがずっと狭く、§5.1 を通る値でもこの外に出ることがあります。

## 意味

他の観点の数値だけを取り繕う抜け道を塞ぐ、最低限の整合チェックです。**打ち切り整合**は論理の不変量——まだ追跡が終わっていない人の時刻が、辻褄の合わない値になっていないか。**関係の非捏造**は、本物のデータには無い関係を勝手に作り込んでいないか（例：本当はほとんど関係のない「県→FPG（空腹時血糖）」を、実在より強く結びつけて作る）。したがって、県・性別・喫煙から**発症率**への関係を本物より強く作り込むと、ここで減点され得ます（発症構造を作り込むときも本物より強めすぎないこと）。逆に、本物にある関係を**ぼかして弱める**のは正当な匿名化なので、減点の対象にはしません。なお、関係の強さを測るものさし（割る値）は、 $C$  を測るときも**本物  $B$  の標準偏差**を使います。 $C$  自身のばらつきで割ると、値をならして散らばりを縮めた加工——たとえば  $k$ -匿名化——が、実際には関係を強めていないのに「強めた」と判定されてしまうためです。

**生理的にありえない値**（検査値が範囲外）は、ここで少し減点するのではなく、提出時の**値域チェック**で受け付けません (§5.1)。

## 6.2 匿名性 Anon（2つの攻撃のうち悪いほう）

匿名性は、匿名化データ  $C$  に対して行われた攻撃の**成功度の裏返し**（ $1 - \text{攻撃の成功度}$ ）。攻撃は2種類——メンバーシップ推論（MIA）と属性推論（AIA）。加工者  $i$  の匿名性は、次の手順で1つの値にまとめます。

1. **攻撃の種類ごとに成功度を出す**。ただし2種類でまとめ方が違います——
  - MIA：攻撃者ごとに成功度を測り、**攻撃者について平均**する（理由は §6.2.1）。
  - AIA：一番よく破った1チームに合わせる（最大）。
2. **2種類のうち、より破れたほう（大きいほう）に合わせる**。
3. その値を1から引く。

$$\text{Anon}(i) = 1 - \max\left(a_{\text{MIA}}(i), \max_j a_{\text{AIA}}(i; j)\right)$$

攻撃の種類の間では**最悪ケース**です——MIA と AIA のどちらか一方でも破られていれば、匿名性はそこで決まります。一方で、MIA の中では**攻撃者について平均**します（AIA は最大のまま）。この非対称には理由があり、§6.2.1 で説明します。

### 6.2.1 MIA 成分（メンバーシップ推論）

**問い**：ある個人が加工者の元データ  $B$  に含まれていたか。

## 測り方

1. 攻撃者ごとに読む。攻撃者  $j$  が付けた確からしさの高い順に候補を並べて ROC を描き、**FPR = 0.01**（ほとんど誤爆しない範囲）での真陽性率（TPR）を読みます。読み取りは ROC 上の線形補間で行います（人数を丸めることはしません）。

確からしさがメンバーかどうかと無関係なら——たとえば乱数で順位を付けたなら——この動作点の TPR も 0.01 になります。以下ではこの水準を「偶然の水準」と呼びます。

2. 希少な候補だけでも読み、悪いほうを採る。同じことを希少な候補だけに絞ってもう一度行い、悪いほう（大きいほう）をその攻撃者の値  $t_j$  とします。希少な患者が露出しているのに、全体の数字で薄めて逃げるのを防ぐためです。
3. 攻撃者について平均する。あなたを攻撃した全チームの  $t_j$  を平均します ( $\beta_{\text{raw}} = \text{mean}_j t_j$ )。
4. まぐれで届く水準を実測して差し引く。提出された確信度はそのままに、「誰がメンバーか」のラベルと「その人が希少かどうか」の印を対にしたまま、攻撃者ごとに代入替えて 1~3 をやり直す、という試行を 20,000 回繰り返します（対にしたまま動かすのは、「希少な候補が何人いて、そのうち何人がメンバーか」という実際には動かない人数構成を、まぐれの側でも保つためです）。得られた値の 95 パーセンタイルを  $\beta_{\text{chance}}$  として、

$$\beta = \max(\beta_{\text{raw}} - \beta_{\text{chance}} + 0.01, 0.01)$$

5. 偶然の水準の何倍かに正規化する。偶然の水準 ( $\beta = 0.01$ ) を 0、その  $K$  倍を 1 として  $[0, 1]$  に写します。

$$a_{\text{MIA}}(i) = \text{clip}((\beta/0.01 - 1)/(K - 1), 0, 1) \quad (K = 12)$$

再現性について。手順 4 の代入替に使う乱数の種は、提出された内容そのもの（全攻撃者の確信度・正解ラベル・希少フラグ）のハッシュから決まります。事務局が種を選ぶ余地はなく、同じ提出物からは誰が計算しても同じ値が出ます。20,000 回という回数は「別の種で回したら得点が変わるか」を実測して決めた値です。

$K$  の見直しについて。 $K = 12$  は予備戦の値です。事務局は、予備戦の終了後に、実際に観測された攻撃の強さに基づいて本戦の  $K$  を見直すことがあります。見直しの有無と、見直す場合の値は、本戦の開始前に公表します。結果を見てから遡って変えることはしません。想定しているのは、予想を超える強力な攻撃が現れてほぼ全チームの匿名性が 0 に張り付き、この目盛りだけでは順位がつかなくなる場合です。

## 意味

- **なぜ的中率（accuracy）でないか。** 候補 1,049 人のうちメンバーは 25~27 人（約 2.4%）しかいないため、「全員を非メンバー」と答えるだけで的中率が約 98% になり、匿名化の良し悪しを測れません。FPR = 0.01 という厳しい動作点で見るのは、攻撃者が最も自信を持って名指した少数の人に何が起きたかを問うためです。平均的な当てやすさではなく、最も露出した個人を見えています。
- **なぜ「全部 0 / 全部 1」が低得点か。** 得点は確信度の順位（ROC）で決まります。全記録に同じ値を出すと順位がつかず ROC が対角線になり、FPR = 0.01 の TPR も偶然の水準になります。
- **なぜ攻撃者について平均するのか。** 攻撃者たちは全員、同じ  $C$  を攻撃しています。違うのは候補に挙がっている人だけなので、攻撃者ごとの数字は「この  $C$  がどれだけメンバーを漏らすか」という同じ一つの量を、別々の人の組で測った反復測定です。平均はその一つの量を精度よく推定するための操作であり、最悪ケースを甘くするためのものではありません。1 チームぶんの測定はメンバーが 25~27 人しかいないため粗

く (FPR = 0.01 は誤爆を約 10 人まで許す動作点です)、最大値をとると**実力ではなく引きの良さ**を拾ってしまいます。∴ **MIA 成分は「広く破られたか」を測ります**。「1 チームだけが破った」ことは匿名性ではなく、攻撃力 (§6.3) の側で評価されます。

- **なぜまぐれの水準を差し引くのか**。メンバーが 25~27 人しかいないため、確信度がメンバーかどうかについて何の情報も持っていないくても、偶然だけで、この水準の数倍まで届いてしまいます。差し引かないと、**実際には何も漏らしていない匿名化データにも減点がつきます**。「あなたのデータを見なくても得られた分は数えない」—— §6.2.2 の AIA で対照を使うのと同じ考え方です。
- **$K = 12$  の意味**。偶然の水準の 12 倍以上の精度でメンバーを当てられたら、匿名性得点は 0 になります。元データの行をそのまま残す、あるいはわずかに揺らしただけの匿名化データは、ここで大幅な減点を受けます。

### 6.2.2 AIA 成分 (属性推論)

このデータは、10 年たっても発症しない人が 9 割近くを占めます。ですから、**全員に「10 年 (最後まで発症せず)」 = `time_hat=10` と答えるだけで、8 割以上が  $\pm 0.5$  年以内に当たってしまいます**。当たった数をそのまま失点にすると、匿名化の良し悪しではなく「打ち切りが多い」というデータの性質を測ることになってしまいます。

そこで、**同じ攻撃者が、コホートに入っていない人でどれだけ当てられたかを差し引きます**。薬の効果を調べるときに、薬を飲まなかった人と比べるのと同じ考え方です。

**標的**での正解率を  $p_m$ 、**対照**での正解率を  $p_c$  とします (標的と対照は §4.2 のとおり) (**1 件ごとの正誤 = 提出した `time_hat` が真の追跡年数と  $\pm 0.5$  年以内なら正解**)。両者から、

$$R = \text{clip}\left(\frac{p_m - p_c}{1 - p_c}, 0, 1\right)$$

分子は「あなたのデータを見たからこそ、余分に当てられた分」。分母は「対照でも当たってしまう分を超えて、まだ当てられる余地」。つまり  $R$  は、**残っていた余地のうち実際に当てられた割合**を表します。元データの行をそのまま残していれば  $R$  は 1 に近づき、特定の個人をそのまま残さずに作れば 0 に近づきます。

希少な患者だけを取り出して同じ計算もして、**全体との悪いほうをあなたの失点**とします。数の少ない患者が露出しているのに、全体の数字で薄めて逃げるのを防ぐためです。ただし希少な患者は人数が少なく偶然の差が出やすいので、**統計的な誤差の範囲に収まる差は罰しません**。

あなたの AIA の失点は、あなたを攻撃した全チームのうち**最もよく当てた 1 チームの  $R$** です。AIA は MIA と違って攻撃者について平均せず、**最大**をとります。AIA の  $R$  は「対照を超えた分」という形で、データを見なくても当たってしまう分を既に差し引いた割合なので、1 チームぶんでも偶然で跳ね上がりにくく、最大をとっても引きの良さを拾いません。

**公平性について**。標的の人数、そのうち希少な患者の人数、発症した人の人数、県・性別の構成、そして対照の人数は、**全チームで同じにそろえてあります**。対照はチームごとに別人で、他のどの配布物にも登場しません。

**共通の性質**：MIA も AIA も、匿名化データに元データの特定の個人がそのまま残ってしまっていないかを見張る役です。個人をそのまま残さずに作れば、どちらもほぼ最小値に抑えられます。ただし「個人が残らないように、ただ分布をならしてばかしただけ」の匿名化データは、有用性——とくに希少群  $U_{\text{rare}}$ ——が落ちるよう設計してあります。**特定の個人はそのまま残さず、集団としての傾向はきちんと再現して有用性も出すことが問われます**。

## 6.3 攻撃力（ベストアタック賞）

攻撃の強さは、総合順位の得点には直接は反映されません。その代わり、独立の**ベストアタック賞**としてランキングします。

### 測り方

標的  $i$ ・攻撃者  $j$ ・観点  $f$ （MIA / AIA）の攻撃成功度を  $a_f(i; j)$ 、攻撃者  $j$  が攻撃した標的の集合（自分のチーム以外の全チーム）を  $I_j$  として、**標的について単純に平均**します。

$$\text{score}_f(j) = \frac{1}{|I_j|} \sum_{i \in I_j} a_f(i; j), \quad \text{AttackScore}(j) = \text{score}_{\text{MIA}}(j) + \text{score}_{\text{AIA}}(j) \in [0, 2]$$

### 意味

- **なぜ標的の難易度で重みづけしないのか。** 攻撃フェーズでは全チームが他の全チームを一括で攻撃するので、**狙う相手を選べません**。誰でも破れる相手で得た点は全員に等しく乗るだけなので順位には効かず、差は結局「破りにくい相手をどれだけ破れたか」でつきます。重みづけをしなくても順位のつき方は同じで、式と説明だけが短くなります。
- **なぜ MIA と AIA を足すのか（min ではなく）。** 攻撃する側にとって、この 2 つは引っ張り合いません——両方を同時に伸ばせます。片方を捨てて片方に全振りする退化した戦い方が無いので、両立を強制する min は不要です。守る側の  $U$  と Anon が minなのは、そちらが本当に引っ張り合うからです。
- **他チームの出来には依存しません。** あなたの攻撃得点は、あなたの攻撃結果だけで決まります。参加者間で相対的に引き伸ばす（最大を 1・最小を 0 にそろえるなど）ことはしませんし、強い攻撃を頭打ちにする上限も設けません。

## 6.4 予備戦と本戦の合計

予備戦と本戦の得点を、次の重みで合計します。

$$\text{最終得点} = 0.1 \times (\text{予備戦}) + 0.9 \times (\text{本戦})$$

総合順位はこの合計後の点数で決めます。攻撃力ランキングも同様です。

予備戦は学習・リハーサル、本戦が本番、という位置づけです。途中参加のチームにもチャンスがあります。

## 7. 運用規則・参加規約

### 7.1 実行基盤

CodaBench で実施します。メール等、他の手段での提出は原則受け付けません。CodaBench 固有の不具合により採点が失敗することもありますので、CodaBench 利用中のトラブルは気兼ねなく事務局に問い合わせてください。

CodaBench が 1 日以上サービスを停止した場合には、ワーキンググループで合議の上、フェーズを延長する場合があります。

## 7.2 提出物の公開

予備戦・本戦それぞれの終了後に、全チームの提出物（CodaBench 提出物）を公開します。予備戦後は攻撃結果も公開されるため、そこから戦略が推測される点はあらかじめ許容してください、本戦のレベルが上がることを狙った措置です。

## 7.3 運営体制

PWS Cup 2026 は PWS Cup 2026 ワーキンググループによって企画され、そのうち 3 名で構成される運営事務局によって運営されます。運営事務局のうち一人は PWS2026 実行委員会副委員長小野元です。事務局にご質問やご相談がある場合は以下のアドレスにメールを送ってください。

PWS 組織委員会 PWS Cup 2026 事務局 \* pwscup2026-info(at)csec.ipsj.or.jp (“(at)” を “@” に置換してください)

運営事務局の 3 名はいずれのチームにも所属せず、公平な運営に努めます。運営事務局以外のワーキンググループのメンバーは競技に参加することができます。ワーキンググループのメンバーの氏名と所属は[ホームページ](#)で確認できます。

競技用のデータ生成および採点プログラムの作成は運営事務局のみによって行われ、それ以外のワーキンググループメンバーには情報が制限されています。競技運営にかかる知見の共有、チーム人数制限等の公平性に関するルールの相談、初期段階の採点ルール構想に対する意見聴取のための情報に限り事務局以外のメンバーと共有しました。また、参加者から運営事務局に対する相談や質問は原則、運営事務局にのみ共有され、参加者自身の意図に反して他のワーキンググループメンバーに開示されることはありません。

ルールブックに明記されていないトラブルが発生した場合は、運営事務局以外のメンバーも含めたワーキンググループ全体で対応を協議します。

## 7.4 監査条項

今年のルールには、同一所属の複数チームが元データ  $B$  を共有し合うなどの**チーム間の共謀**で、匿名性や攻撃の得点を不正に盛れる余地があります。提出物だけでは共謀と本物の巧妙な攻撃を見分けられないため、**事務局の監査権**で抑止します。

- **禁止**：配布物以外の非公開データ、とくに**他チームの元データ  $B$**  を用いた攻撃。（公開データの参照や、手作業・ヒューリスティックによる攻撃は自由です。）
- **事務局の監査権**：不正の疑いがあるチームに対し、事務局は**中間生成物などの提出を求める**ことができます。これは不正の**抑止**が目的で、発動は事務局の**合議のうえ慎重**に行います。
- **判定と責任**：監査を行うか、その結果をどう判定するかは、事務局の合議で決めます。
- **失格**：監査に応じない場合、または不正の証拠が見つかった場合は、当該チームを**失格**とします。
- **位置づけ**：これは公平性を保つための最終手段であり、実際に発動される見込みは低いものです。純粋に競技しているチームが萎縮する必要はなく、**全チーム一律の提出義務・再現義務は課すものではありません**。

## 7.5 LLM 等の生成 AI の利用

- **参加者**：競技のどの場面でも LLM・生成 AI を自由に使えます（加工の設計、攻撃の実装、コード生成、結果の解釈など）。特別な制限は設けません。ただし禁止事項は変わりません — CodaBench や採点系への不正アクセス（クラッキング）、配布物以外の非公開データ、とくに他チームの元データ  $B$  の利用 (§7.4)、および自チームの  $B_i \cdot B_{i,\text{self}}$  の流出 (§3.2)。外部サービスに手元のデータを渡す場合も、漏洩防止の責任は各チームにあります。
- **事務局**：採点結果の検算や、不正の疑いの検証に LLM を用いることがあります。提出物を外部の LLM サービスに入力する場合がある、という前提で参加してください。

## 7.6 賞

計 8 つ。

- **総合 1 位～5 位**（有用性と匿名性の総合順位）。
- **ベストアタック賞**（攻撃力）。
- **オープンサイエンス賞**：コミュニティの発展に役立つ情報共有をしたチームを表彰します。自チーム戦略の解説やコード公開などを発表会で行ったチームの中から審査員の投票で決定します。
- **特別審査員賞**：疫学的な視点から良い発表を選出。

オープンサイエンス賞の審査員は発表会当日に現地参加するワーキンググループメンバーのうち利益相反の少ない者で構成します。特別審査員賞は特別審査員を招待予定です。また、副賞は、総合 4・5 位を除く 6 つの賞に与えます。

---

## 8. スターターキット（配布物一式）

7/30 の説明会で公開します。**練習用のデータ**（本番とは別に作ったもの）で、提出から採点までひととおり試せます。

- **練習用データ**：あなたのコホート  $B_{\text{practice}}$ 、背景データ  $A_{\text{bg}}$ 、自己採点用の拡張版  $B$  ( $B_{\text{self}}$ )、属性推論の標的ファイル (`aia_challenge_<k>.csv`)。
- **スキーマ定義と提出フォーマットの検証器**：列と値域の定義、および提出前に形式・値域・過不足を自分で確かめるツール (§5.5)。
- **ローカル自己採点**：CodaBench と同じ採点器。有用性  $U$  と 4 観点の内訳が出ます (§5.4)。
- **攻撃の実装例** (MIA・AIA)：§4.1・§4.2 で説明した攻撃の実装。自分の  $C$  に当てて手応えを確かめられます。
- **加工の実装例と提出サンプル**：そのまま提出できる形の例。
- **入門ノートブック**：データの読み方から、素朴な匿名化・自己採点・攻撃までを一巡する教材。**任意の教材**であり、ルールと提出フォーマットの正本はこのルールブックと提出サンプルです。

本書の再配布・改変版の公開の条件は追ってご案内します。スターターキットに含まれるコードのライセンスは、キットの LICENSE を参照してください。